



# Erklärbare KI

Warum wir sie brauchen und wie wir dort hinkommen

Dr. Gesina Schwalbe

KI-Landeskonferenz SH 2024

# Outline

Warum brauchen wir XAI?

Wie kann man KI erklären?

Herausforderungen und Zusammenfassung

# Gliederung

## Warum brauchen wir XAI?

Warum brauchen wir Erklärungen?

Warum nicht einfach hineinschauen?

Was ist zu bedenken?

## Wie kann man KI erklären?

Inhärent transparente Modelle

Erklären von Representationen

Erklärbare Surrogate

Feature Importance Methoden

## Herausforderungen und Zusammenfassung

# Warum brauchen wir XAI?

# Warum brauchen wir XAI?

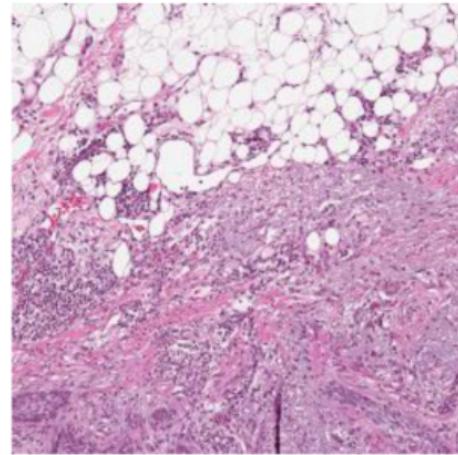


SCHUFA-  
BonitätsAuskunft

# Warum brauchen wir XAI?



SCHUFA-  
BonitätsAuskunft



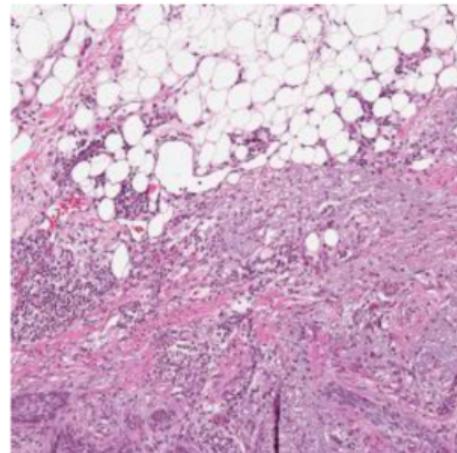
(Pocevičiūtė u. a. 2020, Fig. 6)

# Warum brauchen wir XAI?

SCHUFA-  
BonitätsAuskunft



©Patrick Fallon/Imago



(Pocevičiūtė u. a. 2020, Fig. 6)

# Wo brauchen wir Erklärungen?

Anwendungsfälle:

- ▶ Endnutzende:
  - ▶ (angemessenes!) **Vertrauen**, informierte Zustimmung
  - ▶ Einarbeitung
  - ▶ Regressansprüche
- ▶ Entwicklung und **Fachanwendung**:
  - ▶ Debugging
  - ▶ Knowledge retrieval
- ▶ Gutachten:
  - ▶ Compliance (*Gesetze, Standards*)
  - ▶ **Assessments**, (*Safety, Fairness, ...*)

# Wo brauchen wir Erklärungen?

## Anwendungsfälle:

- ▶ Endnutzende:
  - ▶ (angemessenes!) **Vertrauen**, informierte Zustimmung
  - ▶ Einarbeitung
  - ▶ Regressansprüche
- ▶ Entwicklung und **Fachanwendung**:
  - ▶ Debugging
  - ▶ Knowledge retrieval
- ▶ Gutachten:
  - ▶ Compliance (*Gesetze, Standards*)
  - ▶ **Assessments**, (*Safety, Fairness,...*)

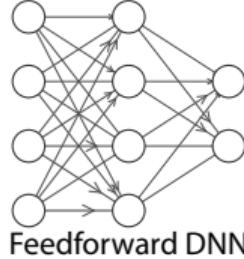
## Anwendungsfelder:

**Sobald automatisierte Entscheidungen Wohlergehen von Menschen beeinflussen!**

- ▶ **Ranking**-Systeme  
(*Kredite, Bewerbungen, ...*)
- ▶ **Medizinische Assistenzsysteme**
- ▶ **Automatisiertes Fahren**
- ▶ **Militärische Entscheidungssysteme**
- ▶ **HMI** in der Produktion
- ▶ ...

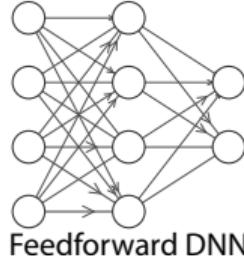
# Hineinschauen ist schwer: Am Beispiel von DNNs.

$$f_{\theta}: \mathbb{R}^n \longrightarrow \mathbb{R}^m$$



# Hineinschauen ist schwer: Am Beispiel von DNNs.

$$f_{\theta}: \mathbb{R}^n \longrightarrow \mathbb{R}^m$$

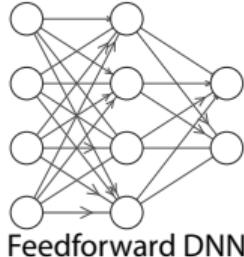


Herausforderungen:

- ▶ **Größe:** YOLOv9, DETR: >50 M Param.  
Llama 3.2: 90 B Param.

# Hineinschauen ist schwer: Am Beispiel von DNNs.

$$f_{\theta}: \mathbb{R}^n \longrightarrow \mathbb{R}^m$$



(Olah u. a. 2017)

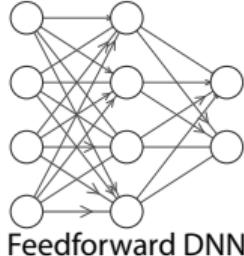


## Herausforderungen:

- ▶ **Größe:** YOLOv9, DETR: >50 M Param.  
Llama 3.2: 90 B Param.
- ▶ **Automatisch erlernte Repräsentationen:**
  - ▶ verteilt ⇒ schwer zu lesen

# Hineinschauen ist schwer: Am Beispiel von DNNs.

$$f_{\theta}: \mathbb{R}^n \longrightarrow \mathbb{R}^m$$



## Herausforderungen:

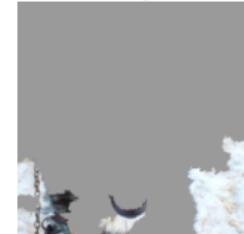
- ▶ **Größe:** YOLOv9, DETR: >50 M Param.  
Llama 3.2: 90 B Param.
- ▶ **Automatisch erlernte Repräsentationen:**
  - ▶ verteilt ⇒ schwer zu lesen
  - ▶ nur Korrelationen ⇒ schwer einzuschätzen



(Marco Túlio Ribeiro u. a. 2016, Fig. 11)



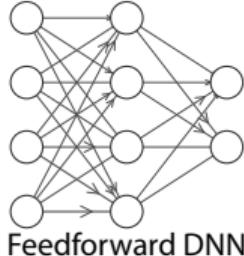
*Husky image*  
misclassified as *Wolf*



**features most influential**  
for the decision

# Hineinschauen ist schwer: Am Beispiel von DNNs.

$$f_{\theta}: \mathbb{R}^n \longrightarrow \mathbb{R}^m$$



## Herausforderungen:

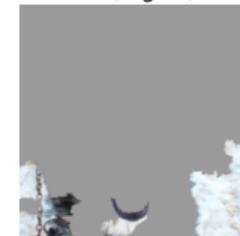
- ▶ **Größe:** YOLOv9, DETR: >50 M Param.  
Llama 3.2: 90 B Param.
- ▶ **Automatisch erlernte Repräsentationen:**
  - ▶ verteilt ⇒ schwer zu lesen
  - ▶ nur Korrelationen ⇒ schwer einzuschätzen



(Olah u. a. 2017)



*Husky image*  
misclassified as *Wolf*



**features most influential**  
for the decision

⇒ black-box.

# Hineinschauen reicht nicht: Es braucht Verständnis.

## Definition (Verstehen)

erfolgreiche Aktualisierung des mentalen Modells; entweder

*mechanistisch* = wie es funktioniert, oder  
*funktional* = was ist der Zweck.

# Hineinschauen reicht nicht: Es braucht Verständnis.

## Definition (Verstehen)

erfolgreiche Aktualisierung des mentalen Modells; entweder *mechanistisch* = wie es funktioniert, oder *funktional* = was ist der Zweck.

## Definition (Stufen von Transparenz)

- ▶ simulierbar = verständlich als Ganzes
- ▶ zerlegbar in simulierbare Teile
- ▶ algorithmisch transparent = mathematisch verständlich

## EU AI Act

### Preamble (72)

[Es] sollte für Hochrisiko-KI-Systeme **Transparenz** vorgeschrieben werden [...]. [Sie] sollten so gestaltet sein, dass die Betreiber in der Lage sind, zu **verstehen**, wie das KI-System funktioniert. [...]

### Artikel 13

1. **Hochrisiko-KI-Systeme** werden so konzipiert und entwickelt, dass ihr Betrieb **hinterreichend transparent** ist, damit die Betreiber die Ausgaben eines Systems angemessen **interpretieren und verwenden können**. [...]

# Was wir wollen: Erklärbare KI (XAI)

## Definition (Erklärb. Entscheidungssys.)

Es gibt einen Mechanismus, der eine Erklärung erzeugt (= *Explanator*) für eine Person (= *Explaineer*), die dadurch eines von (= *Explanandum*) **versteht**:

- ▶ die **Information** in Modell/-teilen,
- ▶ Einfluss von **Modellausgaben**, oder
- ▶ den **Schlussfolgerungsprozess**.

(Lacave u. a. 2001)

# Was wir wollen: Erklärbare KI (XAI)

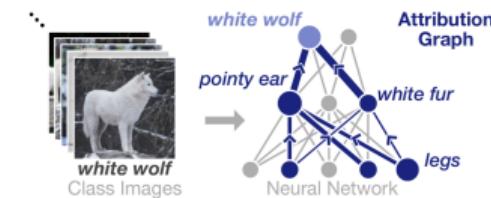
## Definition (Erklärb. Entscheidungssys.)

Es gibt einen Mechanismus, der eine Erklärung erzeugt (= *Explanator*) für eine Person (= *Explaineer*), die dadurch eines von (= *Explanandum*) **versteht**:

- ▶ die **Information** in Modell/-teilen,
- ▶ Einfluss von **Modellausgaben**, oder
- ▶ den **Schlussfolgerungsprozess**.

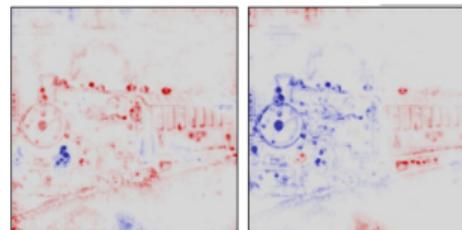
(Lacave u. a. 2001)

⇒ **Wie** funktioniert es? (*global*)

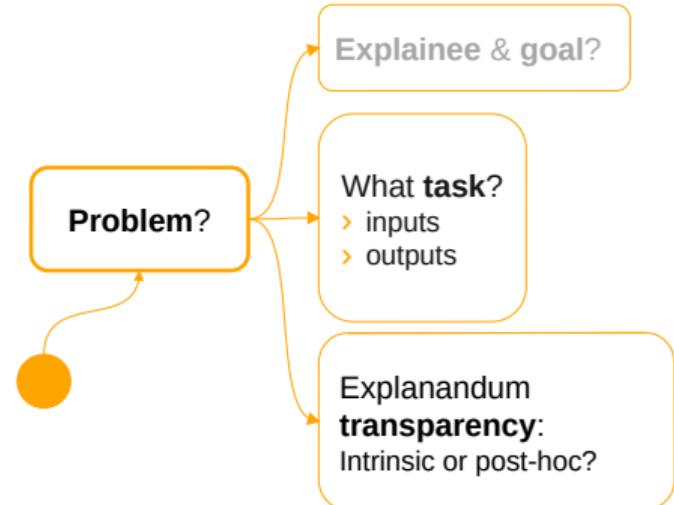


⇒ **Warum** diese Entscheidung? (*local*)

Warum nicht die andere? (*kontrastiv*)

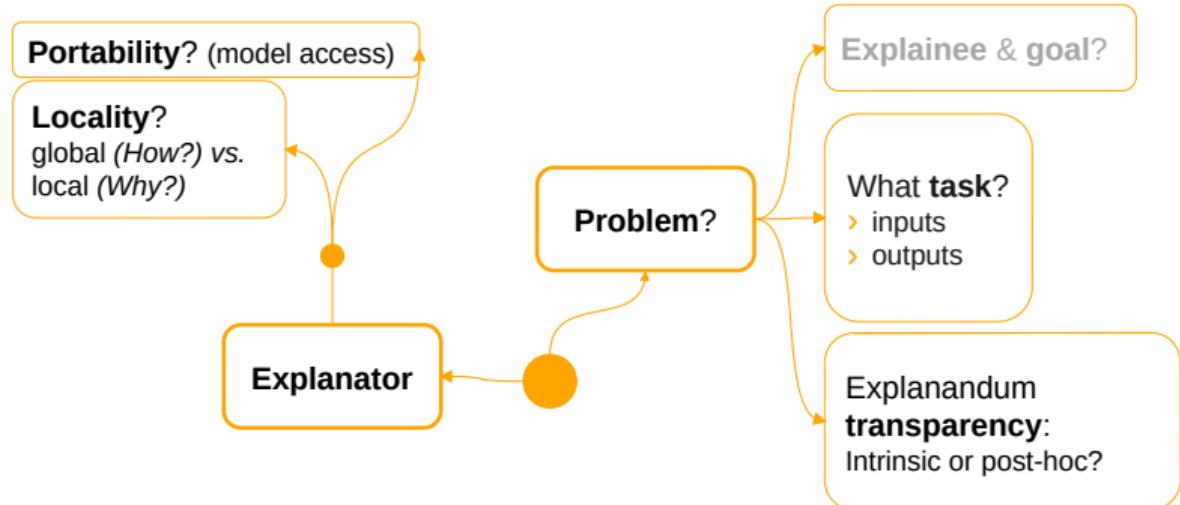


# Was sollte bedacht werden? Eine Taxonomie.



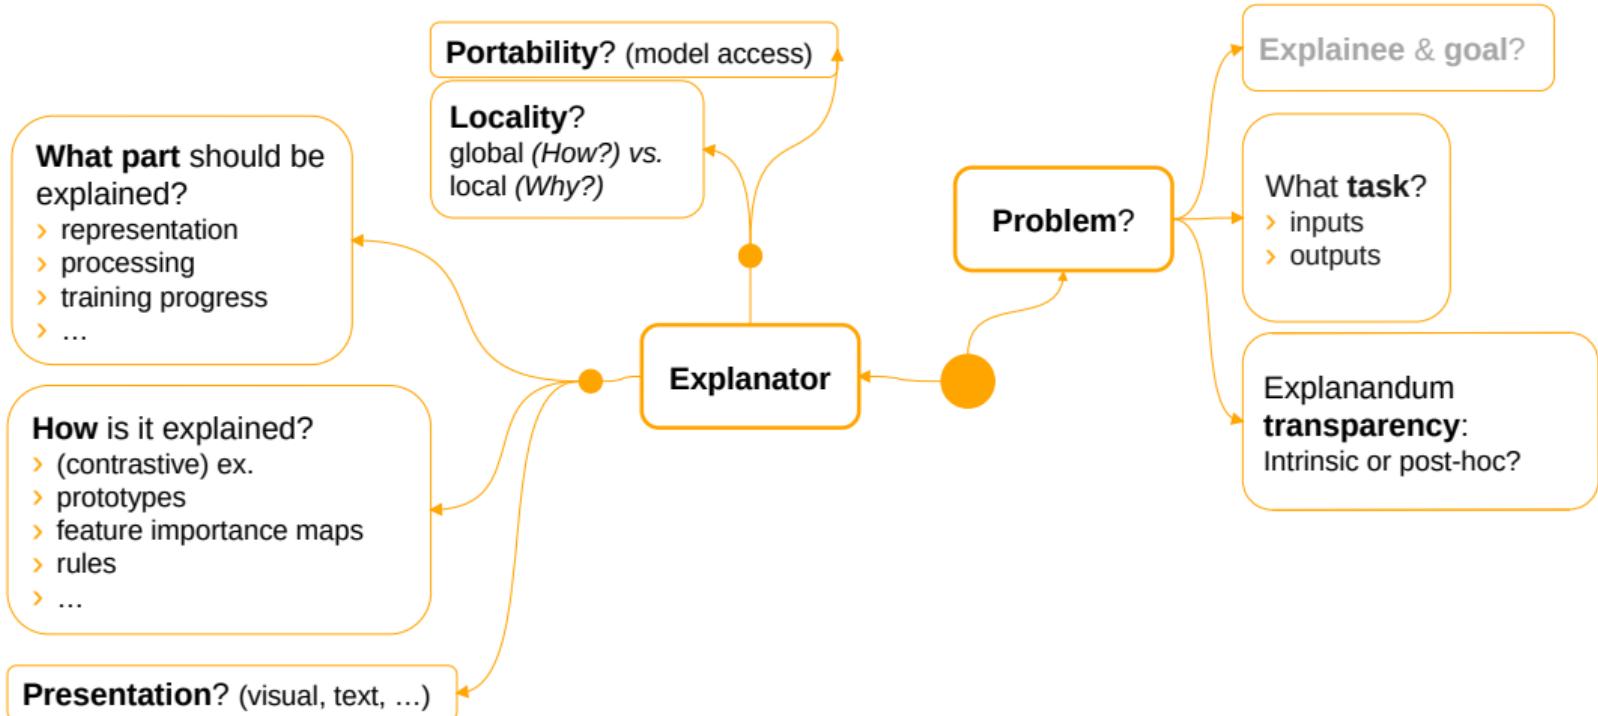
Gesina Schwalbe u. a. (Jan. 2023). „A Comprehensive Taxonomy for Explainable Artificial Intelligence: A Systematic Survey of Surveys on Methods and Concepts“. In: *Data Mining and Knowledge Discovery*. ISSN: 1573-756X. DOI: 10.1007/s10618-022-00867-8. (Besucht am 09.01.2023)

# Was sollte bedacht werden? Eine Taxonomie.



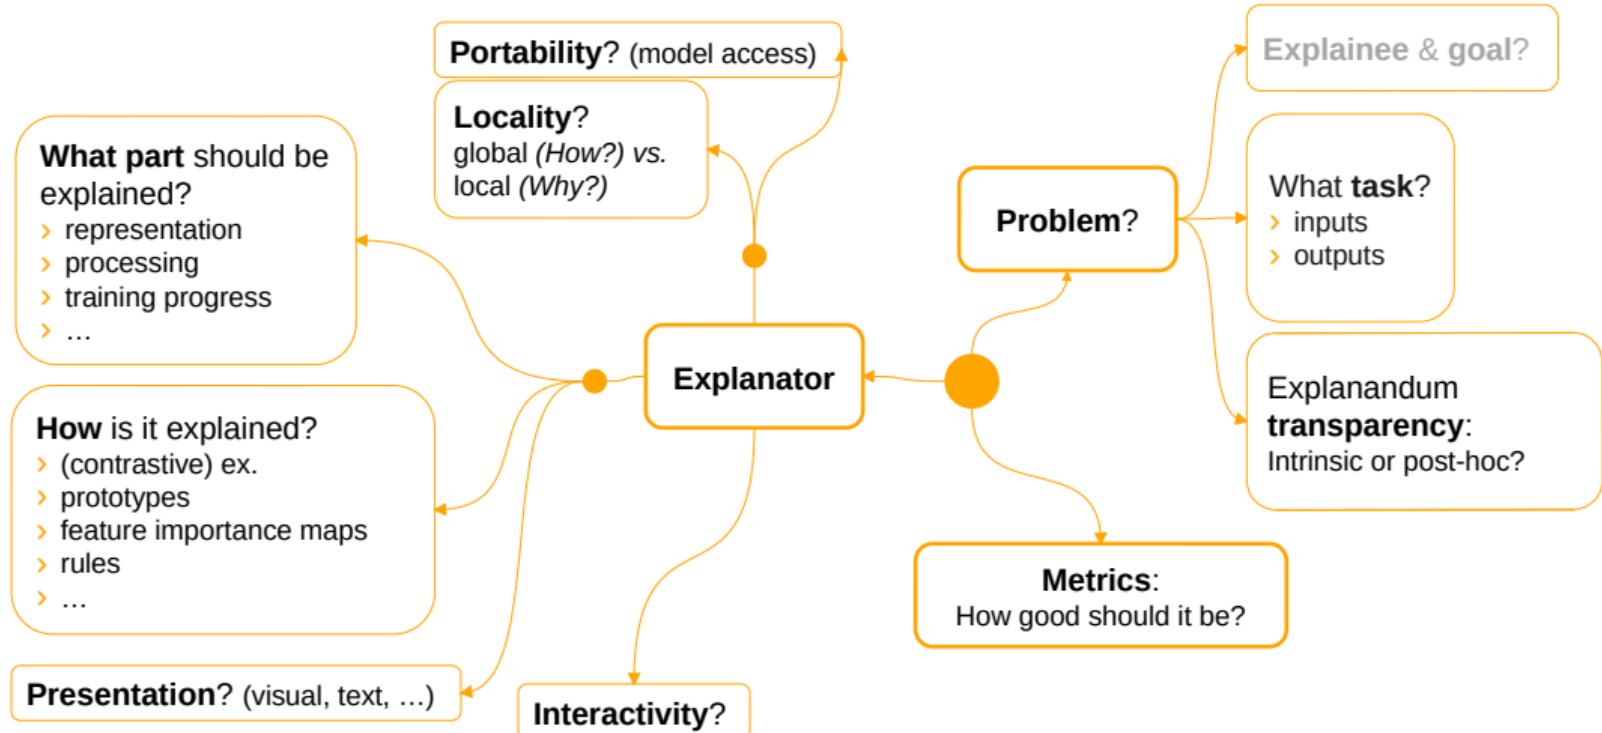
Gesina Schwalbe u. a. (Jan. 2023). „A Comprehensive Taxonomy for Explainable Artificial Intelligence: A Systematic Survey of Surveys on Methods and Concepts“. In: *Data Mining and Knowledge Discovery*. ISSN: 1573-756X. DOI: 10.1007/s10618-022-00867-8. (Besucht am 09.01.2023)

# Was sollte bedacht werden? Eine Taxonomie.



Gesina Schwalbe u. a. (Jan. 2023). „A Comprehensive Taxonomy for Explainable Artificial Intelligence: A Systematic Survey of Surveys on Methods and Concepts“. In: *Data Mining and Knowledge Discovery*. ISSN: 1573-756X. DOI: 10.1007/s10618-022-00867-8. (Besucht am 09.01.2023)

# Was sollte bedacht werden? Eine Taxonomie.



Gesina Schwalbe u. a. (Jan. 2023). „A Comprehensive Taxonomy for Explainable Artificial Intelligence: A Systematic Survey of Surveys on Methods and Concepts“. In: *Data Mining and Knowledge Discovery*. ISSN: 1573-756X. DOI: 10.1007/s10618-022-00867-8<sup>↗</sup>. (Besucht am 09.01.2023)

# Gliederung

Warum brauchen wir XAI?

Warum brauchen wir Erklärungen?

Warum nicht einfach hineinschauen?

Was ist zu bedenken?

Wie kann man KI erklären?

Inhärent transparente Modelle

Erklären von Representationen

Erklärbare Surrogate

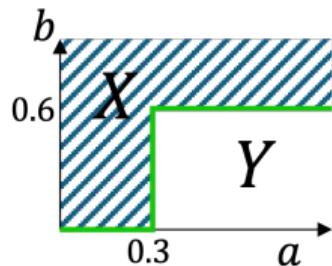
Feature Importance Methoden

Herausforderungen und Zusammenfassung

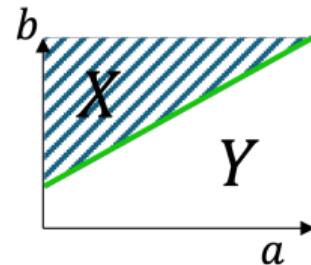
# Inharent transparente Modelle

Wenn mglich, baue es von vorneherein transparent. (Rudin 2019)

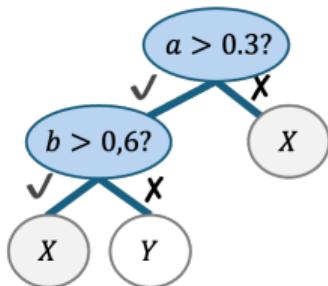
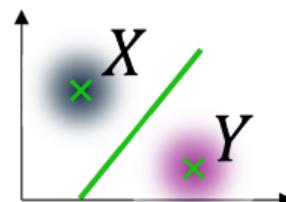
Decision Trees



Linear Models



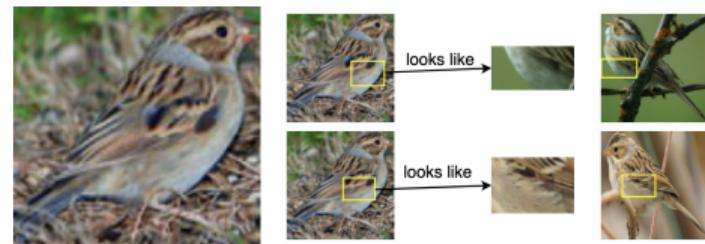
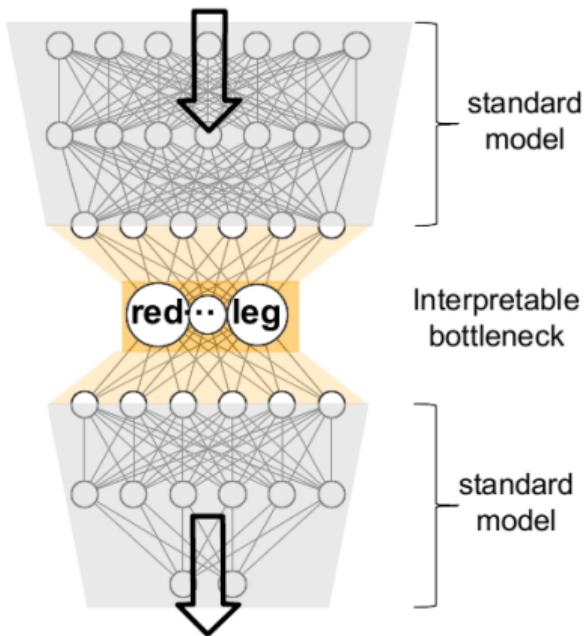
Clusters / Prototypes



$$f(x) = \alpha a + \beta b$$

# Modularisierung: Mischmodelle

# Modularisierung: Mischmodelle



(Chen u. a. 2019)

# Ein erster Schritt: Feature Visualization

Question: What does the output of a network unit/part (z.B., neuron, channel) encode?

(Olah u. a. 2017, Fig. 5)

# Ein erster Schritt: Feature Visualization

Question: What does the output of a network unit/part (z.B., neuron, channel) encode?

Examples  
activating unit strongly



DeepDream  
Prototypes  
= starting image  
optimized to activate  
unit strongly



Baseball—or stripes?  
*mixed4a, Unit 6*

Animal faces—or snouts?  
*mixed4a, Unit 240*

Clouds—or fluffiness?  
*mixed4a, Unit 453*

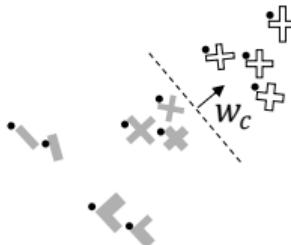
Buildings—or sky?  
*mixed4a, Unit 492*

(Olah u. a. 2017, Fig. 5)

# Concept Embedding Modelle

Ziel: Assoziation zw.

semantischen  
Konzepten,  
z.B., istKopf

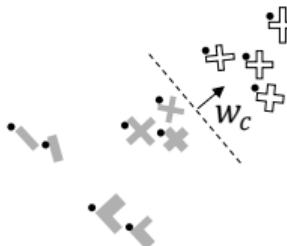


Konzeptaktivierungsvektoren  
 $w_c$  (CAVs) im Vektorraum der  
Zw.ausgabe

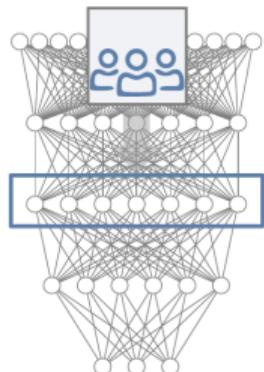
# Concept Embedding Modelle

Ziel: Assoziation zw.

semantischen  
Konzepten,  
z.B., istKopf



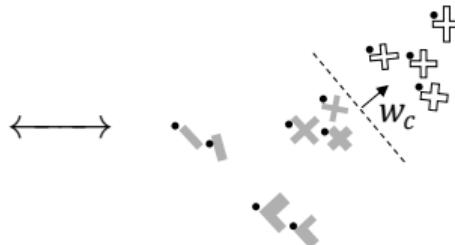
Konzeptaktivierungsvektoren  
 $w_c$  (CAVs) im Vektorraum der  
Zw.ausgabe



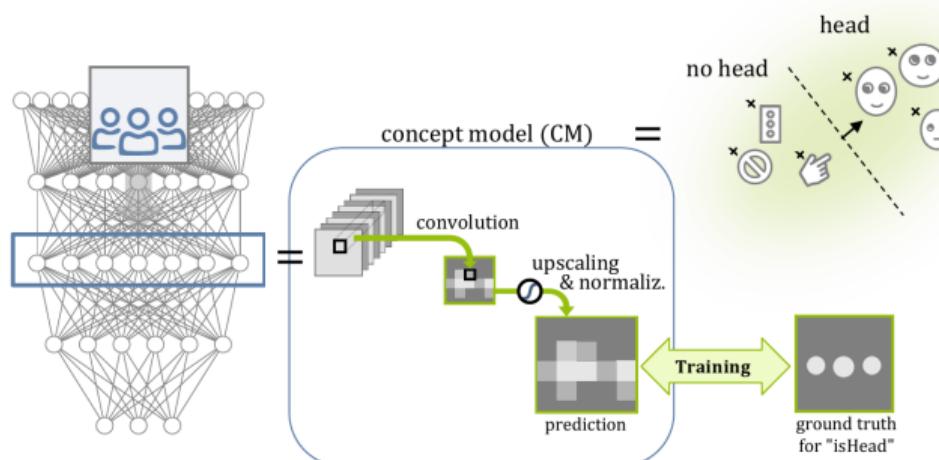
# Concept Embedding Modelle

Ziel: Assoziation zw.

semantischen  
Konzepten,  
z.B., istKopf



Konzeptaktivierungsvektoren  
 $w_c$  (CAVs) im Vektorraum der  
Zw.ausgabe



# Erklärbare Surrogate

Idee: Approximiere DNN(-Teile) mittels transparenterer Modelle.

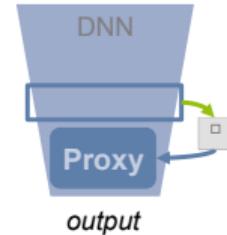
# Erklärbare Surrogate

Idee: Approximiere DNN(-Teile) mittels transparenterer Modelle.

Beispiele:

- ▶ Entscheidungsbäume or -regeln, `face(F) :- contains(F, A), isa(A, nose), contains(F, B), isa(B, mouth), top_of(A, B), contains(F, C), top_of(C, A)`

CA-ILP (Rabold u. a. 2020)



# Erklärbare Surrogate

Idee: Approximiere DNN(-Teile) mittels transparenterer Modelle.

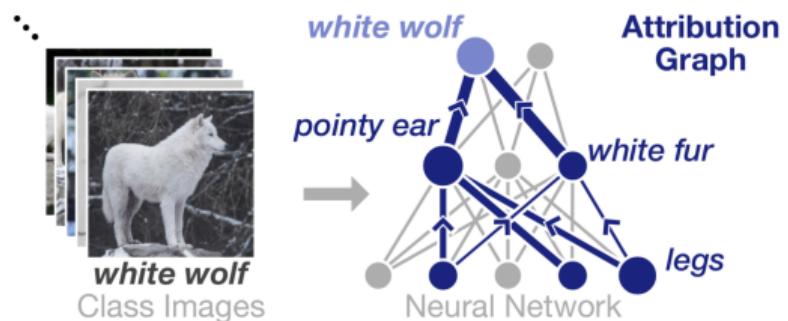
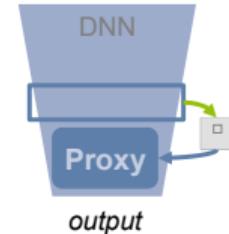
Beispiele:

- ▶ Entscheidungsbäume or -regeln, `face(F) :- contains(F, A), isa(A, nose), contains(F, B), isa(B, mouth), top_of(A, B), contains(F, C), top_of(C, A)`  
*CA-ILP* (Rabold u. a. 2020)
- ▶ Abhängigkeits- / Informationsflussgraphen,

z.B., *SUMMIT* (Hohman u. a. 2020)



Gesicht / kein Gesicht



(Hohman u. a. 2020, Fig. 2)

# Erklärbare Surrogate

Idee: Approximiere DNN(-Teile) mittels transparenterer Modelle.

Beispiele:

- ▶ Entscheidungsbäume or -regeln,

CA-ILP (Rabold u. a. 2020)

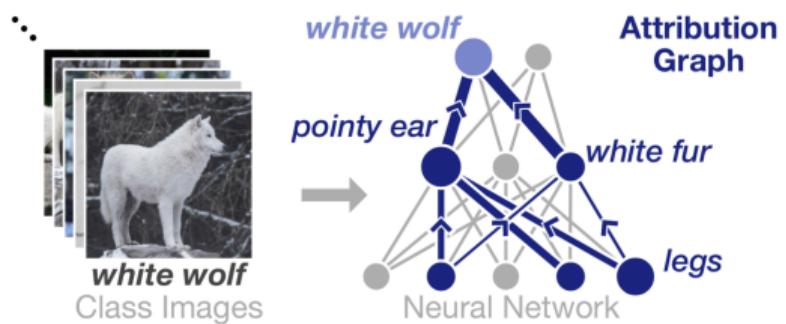
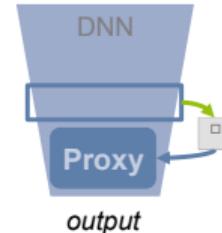
- ▶ Abhängigkeits- /  
Informationsflussgraphen,

z.B., SUMMIT (Hohman u. a. 2020)

- ▶ Lokale lineare Approximationen



Gesicht / kein Gesicht

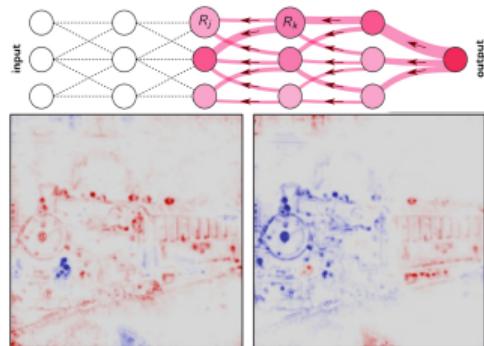


(Hohman u. a. 2020, Fig. 2)

# Feature Importance Methoden

White-box:

**backpropagation- oder  
gradientbasiert**



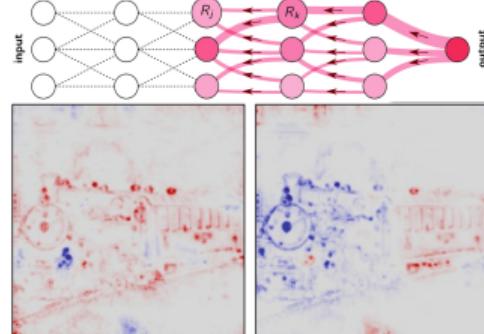
(Montavon u. a. 2019, Figs. 10.2-3)

z.B., LRP (Montavon u. a. 2019),  
SmoothGrad (Smilkov u. a. 2017)

# Feature Importance Methoden

White-box:

**backpropagation- oder  
gradientbasiert**

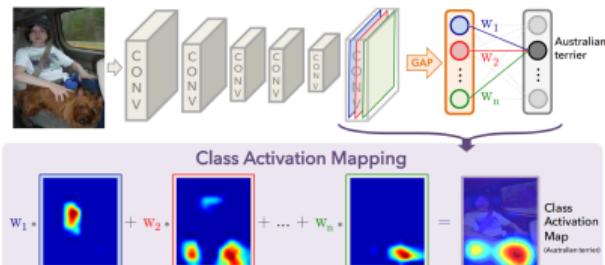


(Montavon u. a. 2019, Figs. 10.2-3)

z.B., *LRP* (Montavon u. a. 2019),  
*SmoothGrad* (Smilkov u. a. 2017)

Gray-box:

**Activation map basiert**

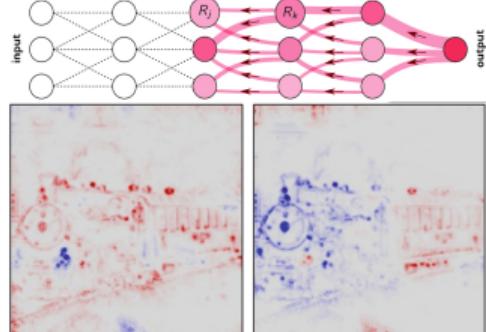


(Zhou u. a. 2016, Fig. 2)

z.B., *Grad-CAM* (Selvaraju u. a. 2017),  
*SIDA* (Muddamsetty u. a. 2020)

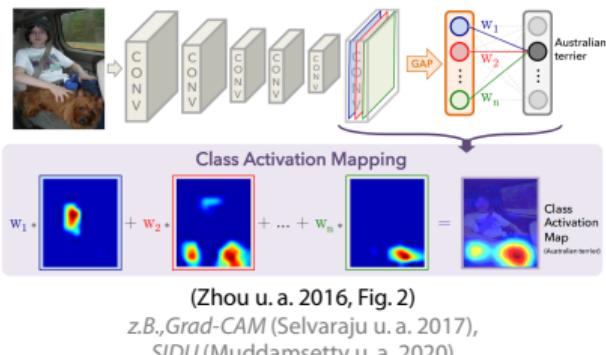
# Feature Importance Methoden

White-box:  
**backpropagation- oder  
gradientbasiert**



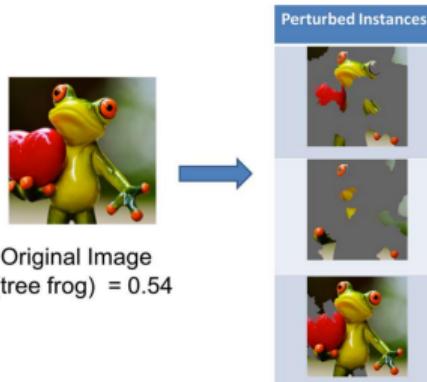
(Montavon u. a. 2019, Figs. 10.2-3)  
z.B., LRP (Montavon u. a. 2019),  
SmoothGrad (Smilkov u. a. 2017)

Gray-box:  
**Activation map basiert**



(Zhou u. a. 2016, Fig. 2)  
z.B., Grad-CAM (Selvaraju u. a. 2017),  
SIDU (Muddamsetty u. a. 2020)

Total black-box:  
**Perturbationsbasiert**



(Marco Túlio Ribeiro u. a. 2016, Fig. 4)  
LIME (Marco Túlio Ribeiro u. a. 2016),  
SHAP (Lundberg u. a. 2017),  
RISE (Petsiuk u. a. 2018)

# Gliederung

Warum brauchen wir XAI?

Warum brauchen wir Erklärungen?

Warum nicht einfach hineinschauen?

Was ist zu bedenken?

Wie kann man KI erklären?

Inhärent transparente Modelle

Erklären von Representationen

Erklärbare Surrogate

Feature Importance Methoden

**Herausforderungen und Zusammenfassung**

# Wonach auswählen?

1. Anforderungen: Kenne Ziele & Bedarf (Taxonomie!)

*Kreditscoring: z.B.,  
lokale Feature Importance  
für Laien*

# Wonach auswählen?

1. Anforderungen: Kenne Ziele & Bedarf (Taxonomie!)

Kreditscoring: z.B.,  
lokale Feature Importance  
für Laien

2. Design:

- ▶ Bevorzuge **transparente** Modelle wo möglich;  
balanciere Erklärbarkeit and Performanz aus
- ▶ Bevorzuge **kausale** and **kontrastive** Erklärungen

Lineares Modell, Entschei-  
dungsbaum?

Was ändern,  
um den Score zu bessern?

# Wonach auswählen?

1. Anforderungen: Kenne Ziele & Bedarf (Taxonomie!)

Kreditscoring: z.B.,  
lokale Feature Importance  
für Laien

2. Design:

- ▶ Bevorzuge **transparente** Modelle wo möglich;  
balanciere Erklärbarkeit and Performanz aus
- ▶ Bevorzuge **kausale** and **kontrastive** Erklärungen

Lineares Modell, Entschei-  
dungsbaum?

3. V&V: Nachmessen!

- ▶ Verständlichkeit → **nachfragen!**
- ▶ Modelltreue, Abdeckung
- ▶ Skalierbarkeit
- ▶ ...

Was ändern,  
um den Score zu bessern?

Können Testnutzer  
ihren Score verbessern?

# Wonach auswählen?

1. Anforderungen: Kenne Ziele & Bedarf (Taxonomie!)

Kreditscoring: z.B.,  
lokale Feature Importance  
für Laien

2. Design:

- ▶ Bevorzuge **transparente** Modelle wo möglich;  
balanciere Erklärbarkeit and Performanz aus
- ▶ Bevorzuge **kausale** and **kontrastive** Erklärungen

Lineares Modell, Entschei-  
dungsbaum?

3. V&V: Nachmessen!

- ▶ Verständlichkeit → **nachfragen!**
- ▶ Modelltreue, Abdeckung
- ▶ Skalierbarkeit
- ▶ ...

Was ändern,  
um den Score zu verbessern?

Können Testnutzer  
ihren Score verbessern?

⇒ Viele Frameworks verfügbar! für DNNs, z.B., [captum.ai](#) / [Xplique](#)

# Offene Herausforderungen

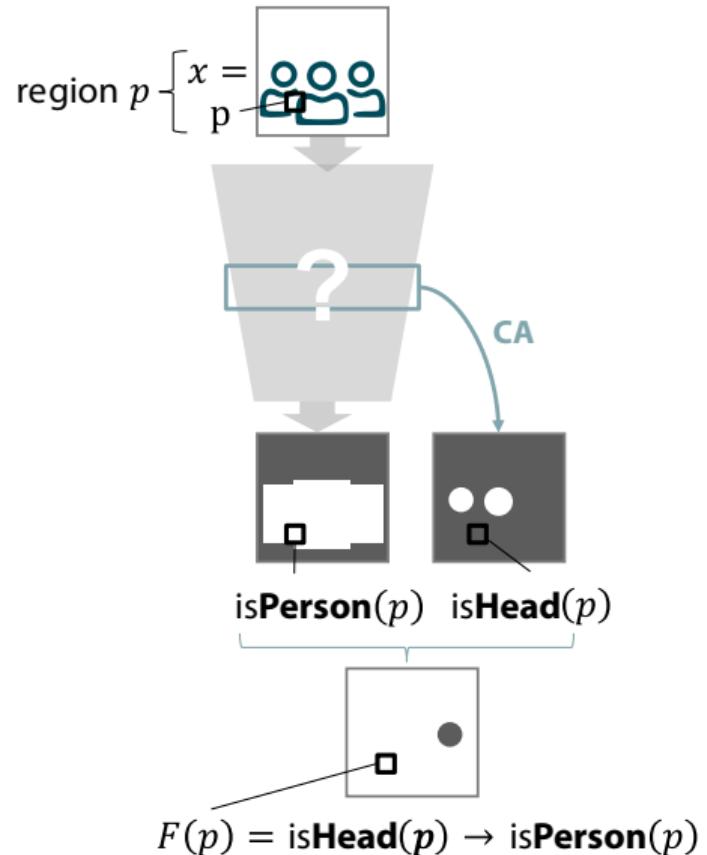
Eine (subjektive) Auswahl:

- ▶ **Evaluation**
- ▶ Reale Anwendungen: Performanz,  
Skalierbarkeit, ...

# Offene Herausforderungen

Eine (subjektive) Auswahl:

- ▶ **Evaluation**
- ▶ Reale Anwendungen: Performanz, Skalierbarkeit, ...
- ▶ **Garantien** anstatt vagen Verständnisses
- ▶ „Es ist fehlerhaft; was nun?“
  - **Handlungsempfehlungen**
  - Verständnis von **strukturellen Mustern**



# Conclusion

Takeaways:

- ▶ **Wir brauchen Erklärungen für KI-Modelle,**  
für Compliance und Qualität.
- ▶ **Es gibt viele Methoden**  
die zusammen viele Anwendungsfälle abdecken.
- ▶ **Es gibt keine eierlegende Wollmilchsau!**  
Beachte Trade-offs und Explainee-Bedürfnisse.

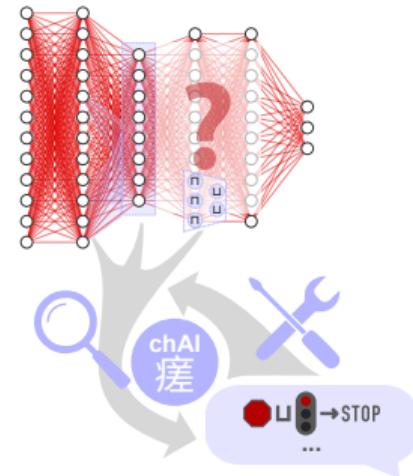
# Conclusion

Takeaways:

- ▶ **Wir brauchen Erklärungen für KI-Modelle,** für Compliance und Qualität.
- ▶ **Es gibt viele Methoden** die zusammen viele Anwendungsfälle abdecken.
- ▶ **Es gibt keine eierlegende Wollmilchsau!** Beachte Trade-offs und Explainee-Bedürfnisse.

Ausblick:

Forschung läuft (z.B., meine 😊),  
Frameworks wachsen.



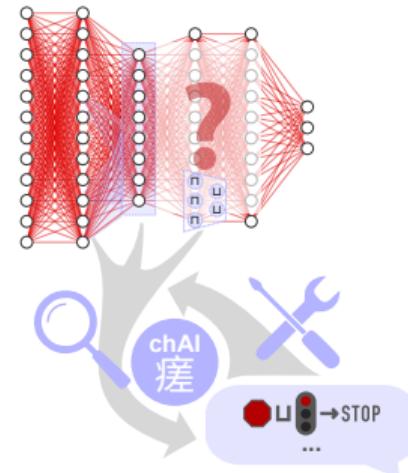
# Conclusion

Takeaways:

- ▶ **Wir brauchen Erklärungen für KI-Modelle,** für Compliance und Qualität.
- ▶ **Es gibt viele Methoden** die zusammen viele Anwendungsfälle abdecken.
- ▶ **Es gibt keine eierlegende Wollmilchsau!** Beachte Trade-offs und Explainee-Bedürfnisse.

Ausblick:

Forschung läuft (z.B., meine 😊),  
Frameworks wachsen.



Fragen?

gesina.schwalbe@uni-luebeck.de  
<https://gesina.github.io>  
ID 0000-0003-2690-2478

# Literaturverzeichnis I

- Chen, Chaofan u. a. (2019). „This Looks like That: Deep Learning for Interpretable Image Recognition“. In: *Advances in Neural Information Processing Systems* 32. Bd. 32. Vancouver, BC, Canada, S. 8928–8939.
- Hohman, Fred u. a. (Jan. 2020). „Summit: Scaling Deep Learning Interpretability by Visualizing Activation and Attribution Summarizations“. In: *IEEE Transactions on Visualization and Computer Graphics* 26.1, S. 1096–1106. ISSN: 1941-0506. DOI: 10.1109/TVCG.2019.2934659 . (Besucht am 14.02.2021).
- Lacave, Carmen und Francisco Dez (Mai 2001). „A Review of Explanation Methods for Bayesian Networks“. In: *The Knowledge Engineering Review* 17. DOI: 10.1017/S026988890200019X .
- Lundberg, Scott M und Su-In Lee (2017). „A Unified Approach to Interpreting Model Predictions“. In: *Advances in Neural Information Processing Systems* 30. Curran Associates, Inc., S. 4765–4774. (Besucht am 30.04.2019).
- Montavon, Grégoire u. a. (2019). „Layer-Wise Relevance Propagation: An Overview“. In: *Explainable AI: Interpreting, Explaining and Visualizing Deep Learning*. Lecture Notes in Computer Science. Springer International Publishing, S. 193–209. ISBN: 978-3-030-28954-6. DOI: 10.1007/978-3-030-28954-6\_10 . (Besucht am 20.06.2022).
- Muddamsetty, Satya M., N. S. Jahromi Mohammad und Thomas B. Moeslund (Okt. 2020). „SIDU: Similarity Difference And Uniqueness Method for Explainable AI“. In: *2020 IEEE International Conference on Image Processing (ICIP)*, S. 3269–3273. DOI: 10.1109/ICIP40778.2020.9190952 .
- Olah, Chris, Alexander Mordvintsev und Ludwig Schubert (Nov. 2017). „Feature Visualization“. In: *Distill* 2.11, e7. ISSN: 2476-0757. DOI: 10.23915/distill.00007 . (Besucht am 20.05.2019).
- Petsiuk, Vitali, Abir Das und Kate Saenko (2018). „RISE: Randomized Input Sampling for Explanation of Black-Box Models“. In: *Proc. British Machine Vision Conf.* BMVA Press, S. 151. (Besucht am 21.01.2019).
- Pocevičiūtė, Milda, Gabriel Eilertsen und Claes Lundström (2020). „Survey of XAI in Digital Pathology“. In: *Lecture Notes in Computer Science* 2020, S. 56–88. DOI: 10.1007/978-3-030-50402-1\_4 . arXiv: 2008.06353 . (Besucht am 24.02.2021).
- Rabold, Johannes, Gesina Schwalbe und Ute Schmid (2020). „Expressive Explanations of DNNs by Combining Concept Analysis with ILP“. In: *KI 2020: Advances in Artificial Intelligence*. Lecture Notes in Computer Science. Springer International Publishing, S. 148–162. ISBN: 978-3-030-58285-2. DOI: 10.1007/978-3-030-58285-2\_11 .
- Ribeiro, Marco Tulio, Sameer Singh und Carlos Guestrin (Aug. 2016). *Local Interpretable Model-Agnostic Explanations (LIME): An Introduction*. <https://www.oreilly.com/content/introduction-to-local-interpretable-model-agnostic-explanations-lime/>. (Besucht am 20.06.2022).
- Ribeiro, Marco Túlio, Sameer Singh und Carlos Guestrin (2016). „Why Should I Trust You?: Explaining the Predictions of Any Classifier“. In: *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*. KDD '16. ACM, S. 1135–1144. ISBN: 978-1-4503-4232-2. DOI: 10.1145/2939672.2939778 .

# Literaturverzeichnis II

- Rudin, Cynthia (Mai 2019). „Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead“. In: *Nature Machine Intelligence* 1.5, S. 206–215. ISSN: 2522-5839. DOI: 10.1038/s42256-019-0048-x  . (Besucht am 25.02.2021).
- Schwalbe, Gesina und Bettina Finzel (Jan. 2023). „A Comprehensive Taxonomy for Explainable Artificial Intelligence: A Systematic Survey of Methods and Concepts“. In: *Data Mining and Knowledge Discovery*. ISSN: 1573-756X. DOI: 10.1007/s10618-022-00867-8  . (Besucht am 09.01.2023).
- Selvaraju, Ramprasaath R. u. a. (Okt. 2017). „Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization“. In: *Proc. 2017 IEEE Int. Conf. Computer Vision*. IEEE, S. 618–626. ISBN: 978-1-5386-1032-9. DOI: 10.1109/ICCV.2017.74  . (Besucht am 14.11.2020).
- Smilkov, Daniel u. a. (2017). „SmoothGrad: Removing Noise by Adding Noise“. In: *CoRR* abs/1706.03825.
- Zhou, Bolei u. a. (2016). „Learning Deep Features for Discriminative Localization“. In: *Proc. 2016 IEEE Conf. Comput. Vision and Pattern Recognition*. IEEE Computer Society, S. 2921–2929. DOI: 10.1109/CVPR.2016.319  .